



Helmut

DOKUMENT 1 VON 2

INTERNER BETRIEBSBERICHT · DATENMOTOR

Helmut · Nohut

VERTRAULICH

# Inhalt

|                                                             |                  |
|-------------------------------------------------------------|------------------|
| 0. Kurzfassung (Abschlussurteil)                            |                  |
| 1. Geprüfter Stand (Phase 1 — Audit-Snapshot)               |                  |
| 2. Geprüfte / nicht prüfbare Bereiche                       |                  |
| 3. Architektur-Überblick: das duale Datenmodell             |                  |
| 4. Vollständiger Prozesskatalog (Phase 3 — Steckbriefe)     | GEPRÜFTER COMMIT |
| 5. Zeitsteuerung (Phase 4)                                  | KI-MODELL        |
| 6. Vollständiger Datenfluss (Phase 2) — Weg eines Dokuments |                  |
| 7. Dokumentlebenszyklus (Phase 5)                           |                  |
| 8. Laufzeitwerte (Phase 3) — vorhanden vs. fehlend          |                  |
| 9. Fehler & Überwachung (Phase 6)                           |                  |
| 10. Datenqualität & Nachvollziehbarkeit (Phase 7)           |                  |
| 11. Ungenutzte Dateien / toter Code (Phase 8)               |                  |
| 12. Landtagsfähigkeit (Phase 9) — Berlin/Brandenburg        |                  |
| 13. Risiken (priorisiert)                                   |                  |
| 14. Offene Gründerentscheidungen                            |                  |

**Erstellt:** 2026-07-16 · **Branch:** `claude/helmut-engine-audit-ifkv6r` · **Modell:** Opus **Methode:** Prüfung gegen echten Code (HEAD = Production), gegen die Production-Datenbank (Supabase `ddckuvvpcytqbyfmbvie`), gegen Vercel-Deployments und gegen die Git-/PR-Historie. Jede Aussage ist mit Datei:Zeile, DB-Abfrage oder Deployment-Beleg unterlegt. Laufzeiten sind **gemessen, nicht geschätzt**; wo keine Messung existiert, steht das ausdrücklich. Es wurde **nichts** an Production-Migrationen, Zeitplänen, Secrets oder Deployments geändert.

Vertraulich · 2

**Wichtiger Lesehinweis zur Belastbarkeit:** Dieser Bericht ersetzt ältere Berichte (`docs/AUDIT_DATENMOTOR_2026-07.md` ist nachweislich veraltet, siehe §11). Er wurde nicht aus Dokumentation abgeleitet, sondern aus Code + Live-Daten.

## 0. Kurzfassung (Abschlussurteil)

- Was geprüft wurde:** Kompletter Datenmotor — Crawling, Speicherung, Textverständnis (KI), Klassifikation, Matching/Relevanz, Entscheidungen, Briefing/Lage/Radar-Ausgabe, alle geplanten Prozesse (9 Vercel-Crons + 1 GitHub-Action), Fehlerbehandlung, Datenqualität, toter Code, Landtagsfähigkeit, Env/Flags/Secrets. Belege aus Code **und** Production-DB.
- Was nachgewiesen funktioniert:** Der Crawl läuft stabil (145 Quellen, 100 % Quellen-Erfolg über 20 protokollierte Läufe, 0 Laufzeitfehler); KI-Verständnis produziert Wissensobjekte (Azure `gpt-5-mini`, Ø 7,9 s/Call, 236/256 erfolgreich); das Briefing wird bei jedem Aufruf deterministisch (0 KI) aus verstandenen Wissensobjekten gebaut und funktioniert für alle drei Testprofile; Quellen-Cutover auf die relationale Architektur ist live; Kostenkontrolle (Tagesdeckel, atomare Reservierung) ist aktiv; KI-Gesamtkosten seit 01.07. ≈ **\$0,92**.
- Was NICHT nachgewiesen ist: Keine einzige persistierte Laufzeit** für Crawl, Pipeline, Lage-Check, Understanding-Batch, Briefing- oder Radar-Aufbau (nur ephemere Vercel-Logs). Der tatsächliche Prod-Wert zentraler Env-Variablen (`HELMUT_MAX_LLM_CALLS_PER_DAY`, `HELMUT_V3_MATCHING`, `HELMUT_AUTH_MODE` u. a.) ist aus der Arbeitsumgebung **nicht lesbar** (Vercel-„sensitive“). Ob die Blob-Daten `sources` / `rawItems` eingefroren sind, ist nur datenseitig, nicht codeseitig belegbar.
- Kritische Risiken:** (a) 1,2-MB-Monolith-Blob `helmut_store` läuft wiederkehrend in 10-s-Timeouts → ein Timeout kann einen ganzen Crawl-Save verlieren; (b) Pipeline-Lock ist **fail-open + nicht-atomar** → Doppelverarbeitung/doppelte KI-Kosten möglich; (c) **kein Pipeline-Fehler** landet je in `systemErrors` (kein `lib/helmut`-Modul ruft `recordSystemError`) → Motorfehler sind nur in flüchtigen Logs sichtbar; (d) der Google-News-Degradations-Alarm ist ein **toter Monitor** (liest ein Feld, das `compactStore` beim Speichern entfernt); (e) 247/314 Wissensobjekte ohne Ebene/Feature-Vektor (Altbestand nie gebackfillt) → Relevanz-Matching wirkt nur auf ~21 % des Bestands.
- Welche Messungen fehlen:** Crawl-/Pipeline-/Lage-/Understanding-/Briefing-Dauer; Pro-Quelle-„zuletzt erfolgreich“; Understanding-Durchsatz je Lauf (persistiert); Klassifikations-/Embedding-Abdeckung als laufende Kennzahl; KI-Budget-Ausschöpfung als Alarm; relational-vs-Fallback-Quellenpfad je Lauf; Alarm-Zustell-Bestätigung.
- Bundestagspilot (überwacht) geeignet? Bedingt ja.** Der fachliche Kern erzeugt nachweislich Vorgänge und Briefings. Für einen \*überwachten\* Piloten fehlen aber die Beobachtbarkeit (Laufzeiten, Pipeline-Fehler-Persistenz) und zwei Härten (Blob-Timeout-Robustheit, atomarer Lock). Diese sind P0/P1 und klein.
- Kern strukturell landtagsfähig? Ja im Kern, nein ohne gezielten Umbau.** Die relationale Quellenschicht, die Geografie-/Ebenen-Modelle (5 Ebenen, `land` / `kommune` real erzeugt), `parliamentTypeOf`, `LANDESPAKET_BY_BUNDESLAND` sind mehr-ebenen-fähig. Berlin/Brandenburg ist aber **dreifach hart gesperrt** und braucht **zwei Codeänderungen** (Landesmodul-Gate entfernen + PARDOK-Live-Modus bauen) plus Datenaktivierung plus Ebenen-Default-Fix. Kein Neubau, aber auch kein reines „Datenflippen“.
- Welche Entscheidungen benötigt werden:** siehe §14 (Prod-Env-Werte bestätigen, Backfill freigeben, Blob-Migration terminieren, Landtag-Cutover-Umfang, Scoring scharfschalten, Persistenz von decisions/matching, Monitoring-Zweitkanal).
- Wo Auditbericht & Umsetzungsplan liegen:** dieses Dokument + `docs/helmut_datenmotor_umsetzungsplan.md`.

## 1. Geprüfter Stand (Phase 1 — Audit-Snapshot)

| Punkt                      | Wert                                                                                                                                                                                                                                 | Beleg                                                                          |
|----------------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|
| Aktueller Branch           | claude/helmut-engine-audit-ifkv6r                                                                                                                                                                                                    | git branch --show-current                                                      |
| Aktueller Commit (HEAD)    | 427295c „Querformat-Sperre ... (#94)" (2026-07-16 09:02 +0200)                                                                                                                                                                       | git log -1                                                                     |
| Production-Commit          | 427295c — Vercel dpl_EaQJBYHpWoWw75fYUva5J9XtVo4C , target=production, READY, branch main                                                                                                                                            | Vercel list_deployments                                                        |
| Lokal == Production?       | Ja. HEAD = Prod-Commit. Working tree sauber (keine lokalen Änderungen).                                                                                                                                                              | git status --short (leer)                                                      |
| GitHub main HEAD           | 427295c (verifiziert)                                                                                                                                                                                                                | GitHub list_commits sha=main                                                   |
| ⚠ Lokaler origin/main -Ref | fce2e65 (2026-07-10, PR #25) — veraltetes Web-Clone-Artefakt, kein Merge-Base zu HEAD, HEAD hat 3 Wurzel-Commits. <b>Nicht</b> die Prod-Linie.                                                                                       | git merge-base origin/main HEAD → keine; git rev-list --max-parents=0 HEAD → 3 |
| Offene Pull Requests       | #88 (Draft, Monitoring-Stack inkl. durationMs -Persistenz, Basis = claude/happy-allen-g5qlua , nicht main ); #70 (Quellen-Audit-Doku → main ); #8 (White-Mode CSS → main )                                                           | GitHub list_pull_requests                                                      |
| Umgebungen                 | Vercel (Projekt helmut-pilot , Team „Nohut", Region fra1, 1 Lambda api/index.js → server.js , maxDuration 300 s); Supabase (Projekt ddckuvvpcytqbyfmbvie , eu-west-1, PostgreSQL 17.6, ACTIVE_HEALTHY, RLS auf allen Tabellen aktiv) | vercel.json ; Supabase list_projects / list_tables                             |
| Relevante Datenbanken      | Zwei Datenwelten (siehe §3): Legacy-Blob helmut_store (4 Zeilen) + relationale „Quellenarchitektur" (~38 Tabellen)                                                                                                                   | Supabase list_tables                                                           |
| Aktive Serverfunktionen    | Genau eine Lambda; api/index.js = module.exports = require("../server")                                                                                                                                                              | api/index.js                                                                   |
| Geplante Prozesse          | 9 Vercel-Crons (UTC) + 1 geplante GitHub-Action ( briefing-watchdog                                                                                                                                                                  | vercel.json , .github/workflows/                                               |
| Externe Dienste            | Azure OpenAI ( gpt-5-mini ), Supabase, Google News (Crawl + URL-Decode), Bundestag-DIP-API, CallMeBot-WhatsApp, Monitoring-Webhook, Web-Push (VAPID)                                                                                 | \$9, .env.example                                                              |
| Verwendete KI-Modelle      | Azure OpenAI gpt-5-mini (685 echte Calls); OpenAI gpt-4.1 = Notfall-Fallback, in Prod durch Azure-Vorrang inaktiv                                                                                                                    | DB llmUsage.model ; ai.js:18-31 , .env.example:1-8                             |
| Aktive Quellenpakete       | 7 source_packages (5 aktiv Bund-Basis, 2 prepared : berlin-basis/brandenburg-basis); 163 retrieval_paths (145 Bund + 18 BE/BB inaktiv)                                                                                               | DB; 05-quellenarchitektur - Analyse                                            |
| Aktive Nutzerprofile       | 3: cem-ince (Pilot), angela-merkel , james-brown (Testpersonen)                                                                                                                                                                      | DB helmut_store -Keys, briefings , mandate_profiles (2)                        |

| Punkt                                | Wert                                                                                                                   | Beleg                                           |
|--------------------------------------|------------------------------------------------------------------------------------------------------------------------|-------------------------------------------------|
| Feature-Flags (managed)              | HELMUT_UNDERSTANDING_GATE=shadow ,<br>HELMUT_PARDOK_DISPATCH=shadow , HELMUT_SOURCE_MODE=on                            | helmut-flags.json ;<br>Allowlist flags.js:31-35 |
| Helmut Datenmotor — Kritischer Audit |                                                                                                                        | Vertraulich · 2                                 |
| Unterschied lokal ↔ Production       | Keiner auf Code-Ebene (HEAD = Prod). Prod-Env-Werte sind „sensitive“ und nicht einsehbar → als Annahmen markiert (§9). | —                                               |

**Applizierte DB-Migrationen (13):** u. a. 20260714\_ko\_classification , 20260717\_llm\_budget\_reservation , source\_architecture . **Verifiziert angewendet:** Spalte knowledge\_objects.decision\_level existiert; Funktion helmut\_reserve\_llm\_call(p\_day,p\_scope,p\_max) existiert; llm\_budget\_counters hat Zeilen. → Die im Code als „freigabepflichtig“ markierten Migrationen sind **in Production real angewendet** (das entkräftet die Hypothese eines stillen KO-Schreibfehlers wegen fehlender Spalte).

## 2. Geprüfte / nicht prüfbare Bereiche

**Geprüft (belegt):** Cron-Verdrahtung & Autorisierung; Crawler (Fetch, RSS/HTML, Google-News-Decode, PARDOK-Streaming); Dedup (2 Mechanismen); Storage-Layer inkl. compactStore /Retention/Locks; Understanding (Clustering, KI-Call, Schema, Klassifikation, Feature-Vektor, Gate, Budget); Matching/Decisions/Scoring; Briefing-/Lage-/Radar-Ausgabe; Dokumentlebenszyklus; Fehlerpfade & Monitoring; Landtag-/Cem-Hardcoding; toter Code; Env/Flags/Secrets. Datenseitig: Crawl-Läufe, LLM-Nutzung, Gate-Telemetrie, Wissensobjekte, Rohdokumente, Briefings, Decisions, Matching, Systemfehler.

**Nicht prüfbar / ungeklärt (ausdrücklich markiert):**

- Prod-Env-Werte** (Vercel „sensitive“): HELMUT\_MAX\_LLM\_CALLS\_PER\_DAY (50 vs. 100?), HELMUT\_V3\_MATCHING , HELMUT\_V3\_LAZY\_UNDERSTANDING , HELMUT\_LLM\_BUDGET\_FAIL\_CLOSED , HELMUT\_UNDERSTANDING\_LOCK , HELMUT\_LLM\_RESERVE\_UNDERSTANDING , HELMUT\_AUTH\_MODE , HELMUT\_DIP\_PRIMARY , HELMUT\_MORNING\_PUSH\_ALL\_PROFILES , HELMUT\_MONITORING\_WEBHOOK\_URL . → aus Verhalten/Datenbestand abgeleitet, entsprechend gekennzeichnet.
- Ephemere Laufzeiten:** Vercel-Runtime-Logs decken nur die letzten 24 h ab; historische Cron-Laufzeiten sind nirgends persistiert → nicht rekonstruierbar (§8).
- Einfrier-Status der Blob-Daten** ( sources =144, rawItems =466): Code liest/schreibt sie weiter — ob die Daten stillstehen, ist datenseitig zu klären, nicht codeseitig.
- PARDOK-Shadow-Ertrag** auf Production: Dateiablage ist auf Vercel read-only → keine persistente BE/BB-Shadow-Messung.

## 3. Architektur-Überblick: das duale Datenmodell

Der Motor fährt **zwei parallele, nicht synchron gehaltene Speicher:**

**(A) Legacy-JSON-Blob** helmut\_store (4 Zeilen, Supabase):

| id              | Größe   | wichtige Keys                                                                                                            |
|-----------------|---------|--------------------------------------------------------------------------------------------------------------------------|
| main            | 1,24 MB | crawlRuns , systemErrors , briefings , politicalItems , sources (144), rawItems (466), lageChecks , pipelineDebugReports |
| main-p-cem-ince | 734 KB  | per-Nutzer: briefings , communicationDrafts , politicalItems ...                                                         |

| id                 | Größe | wichtige Keys                                                                                  |
|--------------------|-------|------------------------------------------------------------------------------------------------|
| main-auth          | 85 KB | llmUsage (1878), pipelineLocks , systemErrors (59), sourceModeShadowLastRun , sessions , users |
| main-p-james-brown | 364 B | Helmut Datenmotor — Kritischer Audit<br>quasi leer (Testpersona)                               |

Vertraulich · 2

→ Bei **jedem** Schreiben läuft `compactStore` (storage.js:2118) und kappt hart (crawlRuns ≤ 30, zusätzlich `saveCrawlRun` ≤ 20; rawItems ≤ 600; systemErrors ≤ 300; llmUsage ≤ 5000). Der **1,24-MB-Blob** `main` ist die dokumentierte Timeout-Quelle (§9).

(B) Relationale „Quellenarchitektur“ (seit Cutover `HELMUT_SOURCE_MODE=on` die aktive Quellenwahrheit):

| Gefüllt                                       | Zeilen   | Leer (angelegt, ungenutzt)                              |
|-----------------------------------------------|----------|---------------------------------------------------------|
| raw_documents                                 | 5733     | sources , political_items , llm_usage (!), topic_memory |
| knowledge_objects                             | 314      | interactions , office_outputs , ko_relations            |
| document_findings                             | 1463     | electoral_districts , matching_weights                  |
| ko_document_links                             | 1230     | path_expected_topics , path_expected_entities           |
| gate_shadow_events                            | 4543     | personalized_recommendations , daily_tasks              |
| decisions                                     | 98       | communication_drafts , user_notes , priority_changes    |
| matching_results                              | 38       | pipeline_locks (Locks liegen im Blob, nicht hier!)      |
| briefings                                     | 13       |                                                         |
| retrieval_paths / package_paths               | 163/165  |                                                         |
| geographies / political_entities / publishers | 50/73/64 |                                                         |

**Zentrale Wahrheit:** Die \*Laufzeit-/Betriebsdaten\* des Motors (Crawl-Läufe, Kosten, Fehler, Locks) leben im **Blob**; die \*Inhaltsdaten\* (Dokumente, Wissensobjekte, Fundstellen) leben **relational**. Das erklärt viele Diskrepanzen unten (z. B. „savedItems“ vs. echte neue Dokumente).

## 4. Vollständiger Prozesskatalog (Phase 3 — Steckbriefe)

Zeiten: Vercel-Crons sind **fix in UTC**. Berlin = UTC+2 (Sommer/CEST, aktuell) bzw. UTC+1 (Winter/CET). Autorisierung aller Crons: `authorizeCron` (server.js:4774) — **fail-closed** (kein `CRON_SECRET` → 503; falsch → 403; Query-Secret nur wenn `HELMUT_ALLOW_QUERY_SECRETS=true` , Default aus).

### 4.1 /api/cron/crawl — Quellen-Crawl (Kernprozess)

- Zweck:** Alle Profil-Quellen abrufen, Rohdokumente speichern, Understanding/Matching/Decisions anstoßen.
- Ausführungsort/Datei/Funktion:** Vercel-Lambda → `server.js:711-714` → `scheduler.js:168 runSourceCrawl(politicianId=cemInceProfile.id)` .
- Auslöser/Startzeit/Zeitzone/Häufigkeit:** Vercel-Cron `0 4 * * *` und `0 20 * * *` (UTC) → **06:00 & 22:00 CEST** (05:00 & 21:00 CET). 2×/Tag.

- **Politische Ebene / Mandant:** Bund; **single-tenant** — ohne Login fällt `politicianId` auf `cem-ince` (`server.js:306-308`); nur Admin-Bypass wählt anderes Mandat).
- **Tatsächliche Startzeiten (belegt, 20 Läufe 12.–16.07.):** planmäßig 04:03/16:02/20:02 UTC; zusätzlich manuelle Läufe (07:26, 07:43, 08:33, 09:41, 14:35) — Gründer-Trigger während Merge-Sessions.
- **Max. Laufzeit:** `/api/cron/crawl` hat keinen `withTimeout` → darf bis 300 s (Lambda-Deckel) laufen. `/api/cron/pipeline` (dieselbe Funktion) ist auf 280 s begrenzt.
- **Tatsächliche Laufzeit / Ø / Median / min / max: NICHT MESSBAR** — keine Dauer wird persistiert (§8). `compactStore` strippt `durationMs` (storage.js:2124-2133), und `saveCrawlRun` berechnet gar kein `durationMs` (scheduler.js:283-309).
- **Erfolgsquote / gefundene / neue / doppelte Dokumente (20 Läufe, DB):** 145 Quellen geprüft, **100 % erfolgreich, 0 Fehler**; `newCandidateItems` **konstant exakt 1012** (= Kandidaten-Cap, kein echter Neuheitswert); `savedItems` 862–939 (**überzeichnet**, siehe §7/§8). Echte Neuheit: nur **55 neue raw\_documents** in 24 h.
- **Folgeprozess:** eager-Understanding (KI), Lazy-Understanding-Vormerkung, Matching-Shadow, Decision-Shadow, source-mode-Shadow-Vergleich — alle **fail-safe** (Fehler verschluckt).
- **Wiederholungslogik / Fehlerverhalten:** Kein Retry. Lock-Skip → HTTP 200 „already running“. Shadow-Fehler nur `console.error`, nie `recordSystemError`.
- **Manueller Neustart:** `GET /api/cron/crawl` mit `Authorization: Bearer <CRON_SECRET>`.
- **Überwachung:** keine direkte; nur indirekt über Health-Report-Frische & GitHub-Watchdog (letzterer triggert `pipeline`).
- **Status:** aktiv/produktiv, aber **blind** (Fehler nur in flüchtigen Logs).

#### 4.2 `/api/cron/pipeline` — identischer Crawl, zeitbegrenzt

`0 16 * * * UTC → 18:00 CEST`. `server.js:770-782` → `withTimeout(runSourceCrawl, 280000)`. Loggt `runSourceCrawl ... ms` (ephemer). Ist der Endpoint, den der GitHub-Watchdog auslöst. **De facto der 3. tägliche Crawl.**

#### 4.3 `/api/cron/morning-briefing` — Morgen-Push

`0 5 * * * UTC → 07:00 CEST`. `server.js:716-768` → `buildV3Briefing` (0 KI) + Push. **Single-tenant** außer `HELMUT_MORNING_PUSH_ALL_PROFILES=1` (Default aus). **Persistiert NICHTS** in die `briefings`-Tabelle (nur Push + On-Demand-Build) → erklärt, warum dort nur `slot=lage`-Zeilen liegen. Loggt `build=...ms push=...ms` (ephemer).

#### 4.4 `/api/cron/understanding` — dedizierter KI-Verständnis-Lauf

`30 5 * * * und 30 21 * * * UTC → 07:30 & 23:30 CEST`. `server.js:961-973` → `runPendingUnderstandingShadow` (Budget 240 s). Verarbeitet als `pending` vorgemerkte Vorgänge. **Ruft das Understanding-Gate NICHT auf** (Gate nur im eager-Pfad). **Gibt immer `ok:true` zurück, auch bei `processed=0`** (alle budget-übersprungen) → stille Erfolgsmeldung ohne Arbeit.

#### 4.5 `/api/cron/lage-check` — Lage-Prüfung

`0 10 * * * UTC → 12:00 CEST`. `server.js:867-884` → `withTimeout(runLageCheck, 280000)`. **Läuft OHNE Pipeline-Lock** (scheduler.js:339). Bei starker neuer Lage: faltet frische Items in Wissensobjekte/Decisions (`foldLageItemsIntoV3`).

#### 4.6 `/api/cron/lage-briefing` — Lage-Narrativ-Vorwärmung (einziger KI-Ausgabe-Pfad)

`45 5 * * * UTC → 07:45 CEST`. `server.js:888-914` → `buildLageBriefing` **je Profil** (Loop über alle aktiven Profile; deaktivierte übersprungen). Schreibt `briefings`-Tabelle (`slot=lage`, Upsert `bf-{user}-lage-{Berlin-Tag}`). Erklärt die 13 Zeilen (cem 5 / merkel 4 / brown 4).



4.7 /api/cron/health-report — Morgen-Health-Report (einziger aktiver Alarmweg)

0 6 \* \* \* UTC → 08:00 CEST. server.js:814-865 → buildHealthReport + Zustellung via CallMeBot-WhatsApp + optionaler Webhook. ?dryRun=1 baut ohne Versand. Der Google-News-Achse liegt ein toter Monitor zugrunde (§9).

4.8 /api/cron/pipeline-status — rein lesender Status (kein Cron-Schedule)

server.js:791-810 . Gibt den letzten Crawl-Lauf zurück; durationMs immer null (Kommentar 803-806 bestätigt: „wird erst persistiert, sobald der Monitoring-Stapel gemergt ist“). Wird vom GitHub-Watchdog nach Client-Timeout gepollt.

4.9 GitHub-Action briefing-watchdog.yml — externer Backstop (triggert echten Crawl!)

- Auslöser:** GitHub-Cron 30 5 \* \* \* UTC → 07:30 CEST + manuell.
- Was er tut:** ruft /api/cron/pipeline (= echter V3-Crawl, nicht nur Health-Check; Kommentar Z.4 „Triggert täglich den V3-Pipeline-Lauf, falls Vercels eigener Cron ausfällt“) und prüft die Antwort; Client-Timeout 330 s, danach pipeline-status -Poll. GitHub-Failure-Mail ist der einzige unabhängige E-Mail-Alarm.
- Einschränkung:** prüft nur die Pipeline — nicht Health-Report, nicht Understanding, nicht Kosten.
- Hinweis:** health-watch.yml (aus PR #88) existiert nicht (unmerged). Alle übrigen .github/workflows/\* (staff-backfill x3, pardok-parser, shadow-pilot, sprint9b-verify) sind workflow\_dispatch -only (manuell); ci.yml läuft auf Push/PR.

5. Zeitsteuerung (Phase 4)

Ablauf eines Sommertages (UTC → CEST):

| UTC   | CEST  | Prozess                                  | Art                           |
|-------|-------|------------------------------------------|-------------------------------|
| 04:00 | 06:00 | crawl                                    | Crawl + Understanding (eager) |
| 05:00 | 07:00 | morning-briefing                         | Push (0 KI)                   |
| 05:30 | 07:30 | understanding + GitHub-watchdog→pipeline | KI-Understanding + 3. Crawl   |
| 05:45 | 07:45 | lage-briefing                            | KI-Narrativ (alle Profile)    |
| 06:00 | 08:00 | health-report                            | Alarm/WhatsApp                |
| 10:00 | 12:00 | lage-check                               | Lage-Refresh                  |
| 16:00 | 18:00 | pipeline                                 | Crawl (zeitbegrenzt)          |
| 20:00 | 22:00 | crawl                                    | Crawl + Understanding (eager) |
| 21:30 | 23:30 | understanding                            | KI-Understanding              |

- Parallelität / Kollisionsrisiko:** Um 05:30 UTC überlappen understanding -Cron und watchdog-getriggerte pipeline (die selbst eager-Understanding fährt). Der Pipeline-Lock schützt nur runSourceCrawl , nicht den Understanding-Pfad (globaler Understanding-Lock ist Default aus). → Doppelte KI-Understanding-Calls sind zeitlich möglich; die einzige Bremse ist die Idempotenz (KO existiert bereits).
- Abhängigkeiten:** morning-briefing (05:00) liest die vom 04:00-Crawl erzeugten Wissensobjekte; lage-briefing (05:45) ebenso. Später eintreffende Dokumente werden erst beim nächsten Crawl/Understanding sichtbar.
- Später eintreffende Dokumente:** kein Nachtrag in bestehende Briefings; das V3-Briefing wird bei jedem Read neu gebaut → automatisch aktuell. Das gecachte Lage-Narrativ wird per koSetHash invalidiert.



- **Doppelte Briefings:** ausgeschlossen für Lage (Upsert je `bf-{user}-lage-{Tag}` ). Morgen-Briefing wird nicht persistiert.
- **Verpasster Lauf: keine Catch-up-Logik**, kein Tages-Idempotenz-Marker. Vercel holt verpasste Crons nicht nach; der Code auch nicht. Einziger Ersatz: der GitHub-Watchdog triggert die Pipeline unabhängig.
- **Sommer-/Winterzeit:** Da alle Crons **UTC-fix** sind, verschiebt sich **jeder** Prozess im Winter um **1 h früher** in Berliner Ortszeit (z. B. Morgen-Briefing 07:00 → 06:00). Bewusst zu entscheiden, ob das gewünscht ist.
- **Versehentlicher Doppelstart:** möglich über (a) fail-open-Lock bei Storage-Timeout, (b) 05:30-Überlappung, (c) manuelle Trigger ohne Idempotenz-Schutz.

Helmut Datenmotor — Kritischer Audit

Vertraulich · 2

## 6. Vollständiger Datenfluss (Phase 2) — Weg eines Dokuments

| # | Schritt                      | Datei · Funktion                                                                                                                                                                                                                   | liest                                                                          | schreibt                                                                                               | Fehler / stille Fehler                                                                             | Status                          |
|---|------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|--------------------------------------------------------------------------------|--------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------|---------------------------------|
| 1 | Quelle                       | <code>sources.js</code> , relationaler Plan<br><code>source-mode.js</code><br><code>buildRelationalCrawlPlan</code>                                                                                                                | <code>retrieval_paths / packages / package_paths</code> (bei <code>on</code> ) | —                                                                                                      | Plan leer/ladefehler → <b>still</b> Fallback Alt-Katalog ( <code>console.warn</code> )             | aktiv ( <code>on</code> )       |
| 2 | Abruf                        | <code>crawler.js</code><br><code>crawlAllSources</code> / <code>crawlSource</code> (RSS/HTML; Google-News-Decode; PARDOK-Streaming)                                                                                                | HTTP                                                                           | in-memory Items                                                                                        | per-Quelle <code>try/catch</code> → <code>ok:false</code> in <code>crawlRun.errors</code> (max 20) | aktiv                           |
| 3 | Original-Inhalt              | <b>nicht gespeichert</b> (DSGVO-Datensparsamkeit: nur <code>summary</code> ≤ 240 Zeichen)                                                                                                                                          | —                                                                              | —                                                                                                      | Volltext bewusst verworfen                                                                         | by design                       |
| 4 | Textextraktion               | <code>crawler.js</code><br><code>normalizeRawItem</code> / <code>parseRssItems</code> (Regex, kein DOM)                                                                                                                            | HTML/XML                                                                       | <code>rawItem</code>                                                                                   | keine „Extraktion fehlgeschlagen“-Zustandsklasse pro Dokument                                      | aktiv                           |
| 5 | Speicherung roh              | <code>scheduler.js:221</code><br><code>saveRawItems</code> (Blob) + <code>persistRawDocumentsShadow</code> (relational)                                                                                                            | Blob-Hashes                                                                    | <code>helmut_store.rawItems</code> , <code>raw_documents</code> (Upsert <code>rd-&lt;hash&gt;</code> ) | relationaler Write <b>doppelt fail-safe</b> ( <code>scheduler.js:163+224</code> ) → still 0        | aktiv ( <code>V3_STORE</code> ) |
| 6 | Klassifizierung              | <code>understanding.js:501</code> → <code>classification.js</code><br><code>classifyKnowledgeObject</code>                                                                                                                         | KO-Felder                                                                      | <code>decision_level</code> , <code>political_level</code> (=decision_level), Entitäten, Geografien    | <code>try/catch</code> <b>verschluckt</b> → KO ohne Ebene                                          | aktiv (write-time)              |
| 7 | Wissensobjekt                | <code>understanding.js:448</code><br><code>assembleKnowledgeObject</code> + KI ( <code>ai.requestStructuredJson</code> , <code>gpt-5-mini</code> , <code>KNOWLEDGE_OBJECT_SCHEMA</code> , <code>politicianId:null</code> = global) | Cluster                                                                        | <code>knowledge_objects</code> (Upsert)                                                                | Save-Fehler → <b>still</b> <code>skipped-store</code> (KI-Kosten schon ausgegeben)                 | aktiv                           |
| 8 | Feature-Vektor („embedding“) | <code>understanding.js:522</code><br><code>computeFeatureVectorForKnowledgeObject</code> (Token-Hash, <b>kein</b> semantisches Embedding)                                                                                          | KO                                                                             | <code>embedding</code>                                                                                 | <code>try/catch</code> verschluckt → KO ohne Vektor                                                | aktiv                           |

| #      | Schritt                                 | Datei · Funktion                                                                                                                                                                          | liest                                       | schreibt                                                                                                                                | Fehler / stille Fehler                                                                                   | Status                       |
|--------|-----------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------|----------------------------------------------------------------------------------------------------------|------------------------------|
| 9      | Personen/<br>Themen                     | in KO-Feldern ( <code>mentioned_*</code> ,<br><code>parteien_ausschuesse</code> ) +<br><code>radar.js</code> / <code>radarState.js</code> (2<br>Engines)                                  | KO                                          | —                                                                                                                                       | 2 divergierende<br>Erwährungs-<br>Engines                                                                | aktiv<br><br>Vertraulich · 2 |
| 1<br>0 | Politische<br>Ebene                     | <code>decision_level</code> ∈ {bund, land,<br>kommune, eu, international,<br>unknown}                                                                                                     | —                                           | KO                                                                                                                                      | Casing: Deriver<br>schreibt <b>klein</b> ( <code>bund</code> ), Alt-<br>Daten groß ( <code>Bund</code> ) | aktiv<br>(sparse)            |
| 1<br>1 | Quellenpa<br>ket /<br>Mandatsp<br>rofil | <code>profile-packages.js</code><br><code>resolveProfilePackages</code><br>(Referenzzählung)                                                                                              | Profil, Pakete                              | —                                                                                                                                       | Bund-Basis<br>Pflicht für <b>jedes</b><br>Profil                                                         | aktiv                        |
| 1<br>2 | Relevanzb<br>ewertung                   | <b>on-read</b> <code>decisions.js</code><br><code>decideForUser</code> → <code>matching.js</code><br><code>matchProfileToKnowledgeObjec</code><br><code>ts</code> (deterministisch, 0 KI) | Profil + KOs +<br>Feature-<br>Vektoren      | — (Read-Pfad);<br>Shadow schreibt<br><code>matching_result</code><br><code>s</code> / <code>decisions</code><br><b>nur für cem-ince</b> | Shadow-Fehler<br><code>.catch(()=&gt;n</code><br><code>ull)</code> <b>ohne Log</b>                       | aktiv                        |
| 1<br>3 | Handlung<br>sempfehl<br>ung             | aus KO-LLM-Feld<br><code>recommendation</code> /<br><code>handlungsempfehlung</code>                                                                                                      | KO                                          | —                                                                                                                                       | —                                                                                                        | aktiv                        |
| 1<br>4 | Briefing                                | <code>server.js:1746</code><br><code>buildV3Briefing</code> (0 KI) →<br><code>briefingContract.js</code>                                                                                  | KOs + on-<br>read<br>Decisions +<br>Quellen | — (nicht persistiert)                                                                                                                   | Store-Fehler →<br><code>empty('store</code><br><code>-error')</code>                                     | aktiv                        |
| 1<br>5 | Ausgabe/<br>Speicheru<br>ng             | Lage-Narrativ ( <code>lage.js</code> , <b>1 KI-<br/>Call</b> ) → <code>briefings</code> -Tabelle;<br>Home/Radar on-read                                                                   | KOs                                         | <code>briefings</code> (nur<br>Lage)                                                                                                    | Cache-Fehler<br>still verschluckt<br>→ KI-Neu-<br>erzeugung                                              | aktiv                        |

**Nachvollziehbarkeit (rückwärts):** `decisions` / `matching_results` tragen `knowledge_object_id` + `vorgang_id` ;  
KO→Dokument via `ko_document_links` (N:M); Dokument→Quelle via `document_findings` . **Bruchstelle:** Die  
`briefings` -Tabelle hat **keine** Fremdschlüssel auf `decisions` / `knowledge_objects` (nur  
{`id`,`user_id`,`slot`,`generated_at`,`payload`} ) — die Kette „warum stand das im Briefing“ liegt nur im opaken `payload`  
-JSON. `office_outputs` (die einzige Tabelle mit `decision_id` + `knowledge_object_id` ) ist **leer**.

## 7. Dokumentlebenszyklus (Phase 5)

| Zustand     | Existiert?                            | entsteht durch                                               | gespeichert wo                                             | Retention / Neuversuch /<br>Löschung                    |
|-------------|---------------------------------------|--------------------------------------------------------------|------------------------------------------------------------|---------------------------------------------------------|
| neu         | ✓                                     | <code>saveRawItems</code> /<br><code>toRawDocumentRow</code> | Blob <code>rawItems</code> +<br><code>raw_documents</code> | Blob gekappt auf 600; relational<br><b>nie gelöscht</b> |
| gespeichert | ✓ (implizit,<br>kein Status-<br>Feld) | Upsert <code>rd-&lt;content_hash&gt;</code>                  | <code>raw_documents</code>                                 | idempotent; keine <code>status</code> -<br>Spalte       |

| Zustand                               | Existiert?                  | entsteht durch                                                                                                                                        | gespeichert wo                                                                                    | Retention / Neuversuch / Löschung                                                                                                                         |
|---------------------------------------|-----------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------------------------------------------------------------------------------------|
| zur Verarbeitung vorgesehen (pending) | ✓                           | runLazyUnderstandingShadow → savePendingKnowledgeObject                                                                                               | knowledge_objects.<br>status='pending'                                                            | bleibt bis Understanding; Budget-Skip belässt pending → <b>Retry idempotent</b>                                                                           |
| in Verarbeitung                       | ✗                           | —                                                                                                                                                     | —                                                                                                 | kein <b>processing</b> -Status; nur grobkörniger globaler Lock (Default aus)                                                                              |
| erfolgreich verarbeitet               | ✓                           | assembleKnowledgeObject (KI ok+valide)                                                                                                                | understanding_status='complete'                                                                   | —                                                                                                                                                         |
| relevant / nicht relevant             | ✓ (Relation, kein Dok-Flag) | on-read <b>decideForUser</b> ; Shadow <b>runDecision/Matching</b> (nur cem-ince)                                                                      | <b>decisions</b> / <b>matching_results</b> ; Gate-Telemetrie <b>gate_shadow_events</b>            | keine Löschung stale Zeilen                                                                                                                               |
| doppelt                               | ✓                           | <b>dedupeRawDocuments</b> (content_hash) + <b>dedup-global</b> (3 Stufen: canonical / Fingerprint / Domain+Titel-Ähnlichkeit ≥ 0,72 + 2-Tage-Fenster) | Duplikat → <b>nie</b> eigene Zeile, stattdessen <b>document_findings</b> + <b>finding_count++</b> | —                                                                                                                                                         |
| unvollständig                         | ✓                           | Schema-Validierung schlägt fehl → <b>markUnderstandingFailed</b> ; oder Lese-Qualitätsstatus                                                          | <b>understanding_status</b> ='failed'                                                             | terminal                                                                                                                                                  |
| nicht lesbar                          | ✗ (nur <b>quellenweit</b> ) | Fetch-Fehler <b>ok:false</b>                                                                                                                          | <b>crawlRun.errors</b> (max 20, pro Quelle)                                                       | kein Pro-Dokument-Zustand                                                                                                                                 |
| unbekanntes Format                    | ✗                           | —                                                                                                                                                     | —                                                                                                 | <b>document_type</b> zu 99 % null, nie als Ablehnungsgrund                                                                                                |
| Verarbeitung fehlgeschlagen           | ✓                           | LLM-/Schema-Fehler → <b>markFailed</b>                                                                                                                | <b>understanding_status</b> ='failed' , <b>status</b> bleibt <b>pending</b>                       | <b>kein Auto-Retry</b> (aus <b>listPendingKnowledgeObjects</b> gefiltert)                                                                                 |
| erneuter Versuch geplant              | ✗                           | —                                                                                                                                                     | —                                                                                                 | nur manueller <b>resetFailedUnderstanding</b> (kein Cron-Aufrufer)                                                                                        |
| endgültig fehlgeschlagen              | ✓ (= failed)                | s. o.                                                                                                                                                 | <b>knowledge_objects</b>                                                                          | nie erneut versucht, nie ausgeliefert                                                                                                                     |
| archiviert                            | ✗                           | —                                                                                                                                                     | —                                                                                                 | <b>kein</b> Archiv/Purge/Retention im Storage (grep = 0)                                                                                                  |
| gelöscht                              | ✗ (für Dokumente/ KOs)      | nur DSGVO-Profillöschung ( <b>deleteProfileDataV3</b> , nur nutzergebundene Tabellen)                                                                 | —                                                                                                 | <b>raw_documents</b> / <b>knowledge_objects</b> / <b>ko_document_links</b> / <b>document_findings</b> werden <b>NIE</b> gelöscht; Blob nur <b>gekappt</b> |

**Was mit nicht-für-ein-Briefing-verwendeten Dokumenten passiert:** Sie bleiben **dauerhaft** in **raw\_documents** / **knowledge\_objects** (kein Archiv, keine Löschung, keine Retention). Bei Budget-Engpass bleiben interessante Cluster **pending** und werden idempotent nachgeholt; verstandene, aber nie relevante KOs verbleiben unbegrenzt.

**Datenverlust-Schutz:** Upsert-Idempotenz + Dedup-Fundstellen. **Doppelverarbeitungs-Schutz:** Idempotenz + (schwacher) Lock. **Sichtbarkeit der Zustände:** nur Admin-Reads; kein Zustands-Dashboard, keine Alarmer auf Zustandsübergänge.

## 8. Laufzeitwerte (Phase 3) — vorhanden vs. fehlend

### 8.1 Vorhandene, belegte Messwerte

**Einzige persistierte Laufzeit = pro LLM-Call** ( `llmUsage.durationMs` , geschrieben in `ai.js` → `recordLlmUsage` ). Aggregiert (1878 Einträge, 01.–16.07., Azure `gpt-5-mini` ):

| callType                            | n    | ok  | Ø ms        | Median | min  | max   | Kosten \$ | letzte        |
|-------------------------------------|------|-----|-------------|--------|------|-------|-----------|---------------|
| skipped-understanding-budget        | 1115 | –   | –           | –      | –    | –     | –         | 14.07. 20:03  |
| understanding                       | 256  | 236 | <b>7900</b> | 8276   | 24   | 19278 | 0,5437    | 16.07. 07:37  |
| communicationDraft (Büro)           | 210  | 210 | 3880        | 3647   | 2106 | 12963 | 0,1960    | 16.07. 07:56  |
| koTagsBackfill (Einmal)             | 161  | 161 | 1609        | 1466   | 1121 | 6481  | 0,0303    | 12.07.        |
| skipped-understanding-error         | 68   | –   | –           | –      | –    | –     | –         | 15.07. 14:34  |
| v2ScoreAndPrioritize ( <b>tot</b> ) | 26   | 26  | 9220        | 9472   | 3061 | 13501 | 0,0585    | <b>06.07.</b> |
| helmutAssessment ( <b>tot</b> )     | 25   | 25  | 4714        | 4254   | 2802 | 14782 | 0,0387    | <b>06.07.</b> |
| lageBriefing                        | 6    | 6   | 5247        | 5270   | 3633 | 6464  | 0,0087    | 16.07. 07:39  |
| parliamentAssessment                | 1    | 1   | 2965        | –      | –    | –     | 0,0005    | 03.07.        |

**Gesamt-LLM-Kosten seit 01.07. ≈ \$0,92.** Weitere belegte Betriebszahlen: 20 Crawl-Läufe (100 % Quellen-Erfolg, 0 Fehler); `raw_documents` 5733 (55 neu/24 h); Gate-Telemetrie `verstehen 3088 / zurueckstellen 1415 / parken 40` .

### 8.2 Fehlende Messwerte (müssen im 2. Thread eingebaut werden)

| Prozess                            | Fehlt                                                                                                     | Wo einbauen                                                                                                                                                                                                                                       |
|------------------------------------|-----------------------------------------------------------------------------------------------------------|---------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Crawl / Pipeline                   | Gesamtdauer (Wall-Clock)                                                                                  | <code>scheduler.js:168</code> <code>t0=Date.now()</code> , <code>durationMs</code> in <code>saveCrawlRun</code> (283) <b>und</b> in die <code>compactStore</code> -Whitelist ( <code>storage.js:2124-2133</code> ), sonst sofort wieder gestrippt |
| Lage-Check                         | Dauer                                                                                                     | <code>scheduler.js:339</code> + <code>saveLageCheck</code> -Payload                                                                                                                                                                               |
| Understanding-Batch (eager + Cron) | Loop-Dauer, <code>processed/deferred/reason</code> <b>persistiert</b> , Anzahl <code>skipped-store</code> | eigene Zähler-Zeile im Auth-Store (Muster <code>adminRecoveryLastRun</code> ), nicht im großen Blob                                                                                                                                               |
| Briefing-/Radar-Aufbau             | End-to-End-Dauer (0 KI)                                                                                   | <code>server.js:1746</code> / <code>radar.js:234</code> <code>t0</code> / <code>Δ</code>                                                                                                                                                          |
| Pro-Quelle-Gesundheit              | <code>last_success_at</code> je Quelle                                                                    | beim <code>saveRawDocument</code> je <code>source_id</code> fortschreiben → <code>quality-watchdog</code> <code>pathTelemetry=true</code>                                                                                                         |

| Prozess                              | Fehlt                                                                                  | Wo einbauen                                                  |
|--------------------------------------|----------------------------------------------------------------------------------------|--------------------------------------------------------------|
| Klassifikation/Feature-Vektor        | Abdeckungs-Kennzahl ( <code>decision_level</code> / <code>embedding</code> null-Quote) | Health-Report-Achse                                          |
| Helmut Datenmotor — Kritischer Audit |                                                                                        | Vertraulich · 2                                              |
| KI-Budget                            | Ausschöpfung als <b>Alarm</b> (nicht nur 1115 stille Records)                          | Health-Report-Achse aus <code>getLlmUsage</code>             |
| Quellenpfad                          | „relational vs. Fallback“ je Lauf                                                      | Flag in <code>crawlRun</code> / <code>pipeline-status</code> |

**Fazit Laufzeit:** Für einen \*überwachten\* Piloten ist die Nicht-Persistenz jeder Prozessdauer der größte Beobachtbarkeits-Mangel. PR #88 adressiert genau `durationMs` , hängt aber auf Nicht- `main` -Basis fest.

## 9. Fehler & Überwachung (Phase 6)

**Grundmuster:** Die Pipeline ist durchgängig „fail-safe“ — aber fail-safe heißt hier fast überall \* `console.error` + weiter\*, nicht \*Systemfehler + Alarm\*. `recordSystemError` wird von **KEINEM** `lib/helmut` -Modul aufgerufen (nur `server.js` ). Alle Crawl-/KI-/DB-/Dedup-/Matching-Fehler landen ausschließlich in flüchtigen Vercel-Logs.

| Fehlerklasse                    | Erkennung                                  | Protokollierung                                        | Wiederholung           | sicherer Endzustand            | Warnung/Mensch                  | Datenverlust-Risiko                        |
|---------------------------------|--------------------------------------------|--------------------------------------------------------|------------------------|--------------------------------|---------------------------------|--------------------------------------------|
| Quelle nicht erreichbar         | ja ( <code>ok:false</code> )               | <code>crawlRun.errors</code> (max 20)                  | nächster Lauf          | Lauf läuft weiter              | nur bei aggregierter Fehlerrate | gering                                     |
| leere Antwort                   | ja (empty feed)                            | in <code>errors[]</code>                               | nächster Lauf          | ja                             | nein                            | gering                                     |
| veränderte Seitenstruktur       | schwach (Regex-Parser liefert [])          | ggf. <code>errors[]</code>                             | nächster Lauf          | ja                             | <b>nein</b> (schleichend)       | mittel (unbemerkte Erosion)                |
| defekte/große PDF               | teilw. (PARDOK 64-MiB-Deckel, fail-closed) | <code>errors[]</code>                                  | nächster Lauf          | ja                             | nein                            | gering                                     |
| unbekanntes Format              | <b>keine</b> Zustandsklasse                | —                                                      | —                      | —                              | nein                            | gering                                     |
| Textextraktion fehlgeschlagen   | <b>keine</b> Pro-Dok-Klassen               | —                                                      | —                      | —                              | nein                            | mittel                                     |
| KI nicht erreichbar (Azure 404) | ja (Exception)                             | <code>markFailed</code> + <code>skipped-error</code>   | <b>kein Auto-Retry</b> | <code>failed</code> (terminal) | nein                            | <b>hoch</b> (Vorgang dauerhaft unsichtbar) |
| KI-Timeout                      | ja                                         | wie oben                                               | kein Auto-Retry        | <code>failed</code>            | nein                            | hoch                                       |
| KI-Ergebnis unbrauchbar         | ja (Schema-Validierung)                    | <code>markFailed</code> + <code>skipped-invalid</code> | kein Auto-Retry        | <code>failed</code>            | nein                            | hoch                                       |

| Fehlerklasse                       | Erkennung                                                     | Protokollierung                                             | Wiederholung                | sicherer Endzustand        | Warnung/Mensch     | Datenverlust-Risiko                    |
|------------------------------------|---------------------------------------------------------------|-------------------------------------------------------------|-----------------------------|----------------------------|--------------------|----------------------------------------|
| Datenbankfehler                    | teilw.<br><small>Helmut Datenmotor — Kritischer Audit</small> | <code>console.error</code> : Blob-Timeout → 500 (scope api) | kein Retry                  | evtl. ganzer Lauf verloren | nur als api-Fehler | hoch<br><small>Vertraulich · 2</small> |
| Doppelverarbeitung                 | schwach                                                       | —                                                           | —                           | Lock (fail-open)           | nein               | mittel (Doppelkosten)                  |
| fehlendes Mandatsprofil            | ja ( <code>getActiveProfile</code> neutral)                   | —                                                           | —                           | neutrale Defaults          | nein               | gering                                 |
| falsche Nutzerzuordnung            | —                                                             | —                                                           | —                           | —                          | nein               | ungeklärt                              |
| unvollständiges Briefing           | ja (Leerzustand)                                              | Response-only                                               | —                           | <code>empty('...')</code>  | nein               | gering                                 |
| erfolgreicher Lauf ohne neue Daten | nein                                                          | —                                                           | —                           | <code>ok:true</code> /200  | nein               | —                                      |
| Prozess bleibt ohne Fehler stehen  | nein                                                          | —                                                           | —                           | —                          | nein               | —                                      |
| mehrere gleichzeitige Instanzen    | schwach (Lock fail-open, TOCTOU)                              | —                                                           | —                           | —                          | nein               | mittel                                 |
| Kostenlimit überschritten          | ja ( <code>skipped-budget</code> )                            | 1115 <code>llmUsage</code> - Records                        | idempotent (bleibt pending) | Regel-Fallback             | nein (kein Alarm)  | gering                                 |

#### Belegte Kernbefunde:

- Toter Google-News-Monitor:** `buildHealthReport` liest `crawl.googleUrlResolution` (server.js:3201), aber `compactStore` strippt dieses Feld → `gnr` immer `null` → die als SPOF-Frühwarnung beworbene Warnung **feuert nie**.
- `recordSystemError` -Lücke:** kein Pipeline-Modul meldet je einen Systemfehler → der Motor ist im `systemErrors` -Log unsichtbar.
- Lock fail-open + TOCTOU:** `acquirePipelineLock` (storage.js:1017-1033) ist ein nicht-atomarer Read-modify-write auf dem Auth-Blob und liefert bei Storage-Fehler `true` → unter Blob-Instabilität Doppelverarbeitung. Der einzige echte Doppel-KI-Schutz (globaler Understanding-Lock) ist Default aus und nirgends verdrahtet.
- Blob-Timeout = Datenverlustpfad:** 10-s-AbortController (storage.js:1791); der 1,24-MB-Write ohne Retry → bei Timeout während `saveCrawlRun` / `saveRawItems` geht der ganze Lauf verloren. Belegt: wiederkehrend „Supabase storage timed out 10000ms /rest/v1/helmut\_store“ (58 api-Fehler, zuletzt 16.07. 05:50).
- Stille Erfolge:** understanding-Cron `ok:true` bei `processed=0` ; crawl-Cron 200 bei Lock-Skip; `newCandidateItems` konstant 1012 → niemand bemerkt einen klemmenden Kandidaten-Cap.
- quality-watchdog (10 Achsen):** existiert, wird aber nur im Admin-Read mit `signals:{}` instanziiert → alle Frische-Achsen „unbekannt“, **kein Alarmpfad**.
- Alarmwege:** einziger aktiver = Health-Report 06:00 UTC über CallMeBot-WhatsApp (Gratis-Drittdienst, fail-open/still) + optionaler Webhook. Fällt der Report-Cron aus, merkt es nur der GitHub-Watchdog — der aber nur die Pipeline prüft.

## 10. Datenqualität & Nachvollziehbarkeit (Phase 7)

- Aktualität:** ☒ tagesfrisch ( `raw_documents` bis 16.07. 07:34; KOs bis 16.07. 07:37).
- Vollständigkeit KO-Anreicherung:** ☐ **67/314 Wissensobjekte** haben `decision_level` / `political_level` / `embedding` (Feature-Vektor); **247 sind Altbestand vor 14.07. und wurden nie gebackfillt** (verifiziert: von 83 KOs seit 14.07. haben 65 die Ebene). Der Schreibpfad **funktioniert** (Migration angewendet) — es fehlt der Backfill.
- Ebenen-Verteilung (belegt):** `bund 46, land 8, eu 8, international 3, kommune 2, (null) 247` . → **Multi-Ebenen-Klassifikation funktioniert nachweislich** (auch `land` / `kommune` ).
- „0 x Bund“-Auflösung:** war ein **Casing-Artefakt** — `classification.js` schreibt **klein** ( `bund` ); Alt-/Debug-Daten nutzen `Bund` . Downstream-Filter auf `Bund` verfehlen neue KOs.
- Dubletten:** `raw_documents` 5386 distinct `content_hash` von 5733 → 347 kollidieren (per Fundstelle zusammengeführt, keine echten Dubletten-Zeilen).
- Textextraktion:** Regex-basiert (kein DOM); `summary` ≤ 240 Zeichen (DSGVO). 99 % ohne `document_type` (nie befüllt, aber auch nie als Ablehnungsgrund genutzt).
- Personen/Organisationen/Themen/Ebene:** in KO-Feldern vorhanden; **2 divergierende Erwähnungs-Engines** ( `radar.js` vs. `radarState.js` ) mit unterschiedlicher Strenge → Radar-Tab und „Über dich“-Sektion können abweichen.
- Nutzerzuordnung / Relevanz:** on-read deterministisch für **alle** Profile; die persistierten `decisions` / `matching_results` existieren **nur für cem-ince** und werden im Ausgabepfad **fast nicht gelesen** ( `listDecisions` hat „keinen Produktionsaufrufer“, storage.js:1478).
- Quellenangabe:** ☒ 93 % direkte Links; KO→Dokument via `ko_document_links` .
- Rückwärts-Nachvollziehbarkeit bis ... Nutzer:** ☒ Quelle→Dokument→Fundstelle→KO→Decision/Matching. ☒ **Bruch bei Briefing→Decision** (keine FK-Spalte; nur `payload` -JSON).

## 11. Ungenutzte Dateien / toter Code (Phase 8)

„Laufzeit-tot“ = kein `require` durch `server.js` / `scheduler.js` /anderen `lib` -Code, nur durch `scripts/` .  
Nichts wurde gelöscht (reine Lese-Analyse).

| Fund                                                  | Ort                      | frühere Rolle                      | aktuelle Verwendung                                               | Risiko  | Empfehlung                               |
|-------------------------------------------------------|--------------------------|------------------------------------|-------------------------------------------------------------------|---------|------------------------------------------|
| <code>staff-backfill.js</code>                        | <code>lib/helmut/</code> | Stabschef-Felder-Backfill          | nur <code>scripts/staff-backfill.js</code> (CLI, dry-run-Default) | niedrig | nach <code>scripts/one-off/</code>       |
| <code>quellenarchitektur/migration-mapper.js</code>   | <code>lib/helmut/</code> | Sprint-6-Migration Blob→relational | nur <code>scripts/sprint6-*</code>                                | niedrig | als abgeschlossene Migration archivieren |
| <code>quellenarchitektur/cem-shadow-compare.js</code> | <code>lib/helmut/</code> | Cem-Migrations-Shadow-Vergleich    | nur <code>scripts/sprint6-*</code>                                | niedrig | wie oben                                 |



| Fund                                         | Ort          | frühere Rolle                                                  | aktuelle Verwendung                                                                                                                                                          | Risiko                                                                 | Empfehlung                                            |
|----------------------------------------------|--------------|----------------------------------------------------------------|------------------------------------------------------------------------------------------------------------------------------------------------------------------------------|------------------------------------------------------------------------|-------------------------------------------------------|
| quellenarchitektur/understanding-priority.js | lib/helmut/  | relevanzbasierte Budget-Auswahl (fertig, getestet, nie scharf) | nur scripts/gate-adversarial-test.js                                                                                                                                         | mittel (verdrängt heute relevante späte Vorgänge, Ankunftsreihenfolge) | scharfschalten (Freigabe) — Kern-Fix gegen Aushungern |
| ko-classification-backfill.js                | lib/helmut/  | Altbestand-Ebenen-Nachfüllung                                  | nur scripts/ ( --execute manuell)                                                                                                                                            | hoch (247 KOs ohne Ebene)                                              | einmalig ausführen / an Cron                          |
| generateHelmutAssessment (+Umfeld)           | ai.js:350    | V2-KI-Bewertung                                                | O Aufrufer (V3 nutzt deterministisches buildHelmutAssessment )                                                                                                               | mittel (versehentliche LLM-Reaktivierung)                              | als toten V2-Pfad entfernen (nach Bestätigung)        |
| v2ScoreAndPrioritize                         | —            | V2-Scoring                                                     | nur Test-Fixture-String                                                                                                                                                      | keiner                                                                 | erledigt                                              |
| runMorningBriefing                           | —            | V2-Morgen-Briefing                                             | entfernt (Cron ruft V3)                                                                                                                                                      | keiner                                                                 | erledigt                                              |
| docs/AUDIT_DATENMOTOR_2026-07.md             | docs/        | Alt-Audit (01.07.)                                             | referenziert nicht existierende Dateien ( personalization.js / runtime.js / briefing.js ), Single-Tenant-Vor-V3-Framing                                                      | mittel (irreführend bei Due Diligence)                                 | als überholt kennzeichnen                             |
| docs/V3_MIGRATION_PLAN.md                    | docs/        | „Plan“                                                         | faktisch abgeschlossenes Cutover-Protokoll                                                                                                                                   | niedrig                                                                | umbenennen                                            |
| tote Env-Flags                               | .env.example | —                                                              | HELMUT_TENANT_JWT_MODE (hart false ), SUPABASE_JWT_SECRET / ANON_KEY (nur im stillgelegten JWT-Modus), OpenAI-Pfad (Azure-Vorrang), HELMUT_MONITORING_EMAIL (existierte nie) | niedrig                                                                | dokumentieren/entfernen                               |
| Falsch-verdächtig (LIVE!)                    |              |                                                                | learning.js (server.js:638/702/708/3046), presentation-backfill.js (server.js:953), quality-watchdog.js (server.js:3726)                                                     | —                                                                      | nicht anfassen                                        |

**Falle:** `HELMUT_UNDERSTANDING_GATE=on` und `HELMUT_PARDOK_DISPATCH=on` schalten im aktuellen Code **NICHTS** scharf (der `on` -Arm ist nicht verdrahtet; `pardok` fällt bei `on` still auf `off` ). Wer sie setzt, ändert nichts — **ohne Fehlermeldung**.

**Blob-Keys** `rawItems` / `politicalItems` / `topicMemory` / `sources` : Code liest/schreibt sie **weiter** (nicht tot). Ob die \*Daten\* eingefroren sind, ist datenseitig zu klären (ungeklärt).

**Fehlend:** kein toter-Code-/require-Graph-Report in CI → solche Module fallen nicht automatisch auf.

## 12. Landtagsfähigkeit (Phase 9) — Berlin/Brandenburg

### 12.1 Was strukturell BEREITS mehr-ebenen-fähig ist

- Relationaler Quellenplan ( `source-mode.js` ) ist die aktive Wahrheit; `geographies` mit **5 Ebenen**; `parliamentTypeOf` löst `Landtag` aus `mandate_profiles.politische_ebene` auf (config.js:151-164); `profileCompleteness` kennt „Landtag braucht Bundesland“ (config.js:194); `LANDESPAKET_BY_BUNDESLAND = {berlin, brandenburg}` (profile-packages.js:28-31); Klassifikation erzeugt real `land / kommune` ; `entity_type` -Enum enthält `parliament` / `authority` .
- **BE/BB-Seed (20260717) ist in der Live-DB angewendet:** 4 Entitäten, 14 Publisher, 18 Abrufwege, 18 `path_expected_levels` (alle `land` ), 19 `package_paths` .

### 12.2 Die DREIFACH-Sperre (warum heute 0 sichtbare BE/BB-Items)

1. **Hartes Landesmodul-Gate** in `buildRelationalCrawlPlan` ( `source-mode.js:46-52,112-116 isLandesmodulPath` ) schließt **jeden** `rp-be-` / `rp-bb-` -Weg aus — auch die Google-News/RSS-Wege, **bevor** Status/Paket geprüft werden. → **CODE-Blocker**.
2. **PARDOK hat keinen Live-Modus:** `pardokDispatch` gibt in **jedem** Modus `items:[]` zurück (pardok-dispatch.js:19,72,113); der Live-Pfad ist „bewusst nicht implementiert“. BE/BB-Plenum/Drucksachen können nie in die Pipeline. → **CODE-Blocker**.
3. **Status:** alle 18 BE/BB-Wege `needs_review` + `manual` ; Pakete `berlin-basis` / `brandenburg-basis` `prepared` (nicht `active` ). → **DATEN**.

### 12.3 Ergänzzbarkeit je Element (Data-Flip vs. Codeänderung)

| Element                          | Data oder Code                                                                                                | Beleg                                       |
|----------------------------------|---------------------------------------------------------------------------------------------------------------|---------------------------------------------|
| Neue Parlamente                  | DATA (Entität existiert via Publisher-FK; anreichern)                                                         | 20260717-Seed                               |
| Neue Ausschüsse                  | DATA (keine Landes-Ausschuss-Entitäten geseedet; <code>classification</code> löst nur Bund auf)               | classification.js:127-129                   |
| Neue Ministerien                 | DATA (nur Sammel-Publisher „Ministerien Brandenburg“)                                                         | 20260717-Seed                               |
| Neue Fraktionen                  | DATA (nur <code>group-agh-linke</code> ; SPD/CDU/AfD/BSW/Grüne fehlen)                                        | 20260717-Seed                               |
| Neue Behörden                    | DATA ( <code>authority</code> -Enum vorhanden, ungenutzt)                                                     | 20260713-Migration                          |
| Wahlkreise                       | DATA ( <code>electoral_districts</code> <b>komplett leer</b> ; kein Landtagswahlkreis)                        | DB                                          |
| Regionalmedien                   | DATA (Tagesspiegel/rbb24/MAZ geseedet, <code>needs_review</code> )                                            | 20260717-Seed                               |
| Neue Quellenpakete               | DATA ( <code>prepared</code> → <code>active</code> flippen)                                                   | packages.js:60-70                           |
| Eigene Abrufzeiten               | <b>CODE</b> (Crons global, kein Land-Scheduler)                                                               | vercel.json                                 |
| Eigene Mandatsprofile            | DATA ( <code>mandate_profiles</code> -Zeile Landtag; keine BE/BB-Profile existieren)                          | profile-packages.js:109-114                 |
| Landesspezifische Relevanzregeln | <b>CODE</b> (Bund-Bias in <code>classification</code> / <code>scoring</code> / <code>matching</code> ; s. u.) | classification.js:163-174, scoring.js:97-99 |
| Landesspezifische Briefingregeln | <b>CODE</b> (keine Ebenen-/Land-Filterung in <code>lage.js</code> /Briefing)                                  | —                                           |

12.4 Bund-Bias, der Landtag heute verhindert (produktweit, nicht nur Demo)

- `neutralProfileDefaults` / `blankProfile` setzen für jedes Nicht-Cem-Mandat `politicalLevel='Bund'` , `function='Bundestagsabgeordnete:r'` , `relevantMinistries=['Bundesregierung']` (scheduler.js:1404-1441, server.js:4490-4534, Save-Fallback 4621). → `parliamentTypeOf` klassifiziert ein Mandat ohne explizites `politische_ebene='landtag'` als **Bundestag**.  
Helmut Datenmotor — Kritischer Audit Vertraulich · 2
- Crawl-/Scoring-/Relevanz-Heuristiken mit Default `profile=cemInceProfile` feuern für jedes Profil mit fixen Bundesbegriffen: `itemPoliticalWeight` +35 für `bundesregierung` / `bmas` (scheduler.js:1145); `lageCheckSourceWeight` +120 für `bmas|bundesregierung|bundestag|linke|dgb` (427); `hasGovernmentWork` nur Bundesbegriffe (975); föderale Top-Quelle (prio 94) rangiert über Landtag-Quelle (prio 92).
- `matching.js` Synonymkataloge nur Bundestags-Ausschüsse/Bundesparteien (53-74, 118-126). `DIP` (nur Bundestag, WP 21) wird für jedes Mandat abgerufen (dip.js, scheduler.js:220) — kein Landtags-Pendant.
- **Sauber gegated (nur Demo):** das volle `cemInceProfile` (Die Linke/BMAS/Niedersachsen) und `demoFallback` - Themen greifen nur bei `!authModeOn() && id==='cem-ince'` .

12.5 Urteil Landtag

Der Kern ist strukturell geeignet (relationale Ebenen-Architektur, `land` / `kommune` -Klassifikation, `parliamentTypeOf` , Landespaket-Mapping). **BE/BB ist aber nicht durch reines Datenflippen ergänzbar:** zwingend sind **zwei Codeänderungen** — (1) das harte Landesmodul-Gate entfernen/parametrisieren, (2) den PARDOK-Live-Modus bauen — **plus** Datenaktivierung (Status-Flips, Entitäten, `electoral_districts` , ein Landtags-Mandatsprofil) **plus** der Ebenen-Default-Fix (nicht mehr auto- `Bund` ) **plus** der KO-Backfill. Kein Neubau, aber ein umschriebenes Umbaupaket (siehe Umsetzungsplan P2).

13. Risiken (priorisiert)

| #   | Risiko                                                                                                                    | Schwere  | Beleg                                                              |
|-----|---------------------------------------------------------------------------------------------------------------------------|----------|--------------------------------------------------------------------|
| R1  | 1,24-MB-Monolith-Blob → 10-s-Timeouts, <b>ganzer Crawl-Save verlierbar</b> ; skaliert mit mehr Mandaten schlechter        | kritisch | systemErrors api=58; storage.js:1791/188-195 (kein Retry)          |
| R2  | Pipeline-Lock <b>fail-open + TOCTOU</b> ; Understanding-Lock Default aus → Doppelverarbeitung/Doppel-KI-Kosten, unbemerkt | kritisch | storage.js:1017-1033, 1053-1074                                    |
| R3  | <b>Kein</b> Pipeline-Fehler in <code>systemErrors</code> ; Motor im Fehlerlog unsichtbar                                  | kritisch | grep <code>recordSystemError</code> = 0 in <code>lib/helmut</code> |
| R4  | Toter Google-News-Monitor (liest gestripptes Feld) → SPOF-Frühwarnung feuert nie                                          | hoch     | server.js:3201 vs. storage.js:2124-2133                            |
| R5  | 247/314 KOs ohne Ebene/Feature-Vektor → Relevanz-Matching wirkt nur auf ~21 %                                             | hoch     | DB; understanding.js:500-525                                       |
| R6  | <code>failed</code> -KOs (88 Skips) nie auto-retry → Vorgänge nach einem KI-Fehlertag dauerhaft unsichtbar                | hoch     | storage.js:1524; understanding.js:591-599                          |
| R7  | Keine persistierte Laufzeit → überwachter Pilot ohne Beobachtbarkeit                                                      | hoch     | §8                                                                 |
| R8  | <code>savedItems</code> überzeichnet Durchsatz ~15× (Blob-Cap-Artefakt) → falsche Reporting-Basis                         | mittel   | storage.js:2153-2167; DB 55/24h                                    |
| R9  | Ebenen-Casing ( <code>bund</code> vs. <code>Bund</code> ) → Downstream-Filter verfehlen neue KOs                          | mittel   | classification.js:24 vs. server.js:4972                            |
| R10 | Alarm nur über CallMeBot (fail-open/still) + optionaler Webhook; kein Ack                                                 | mittel   | server.js:3267-3279                                                |

| #       | Risiko                                                                                                                             | Schwere | Beleg                                             |
|---------|------------------------------------------------------------------------------------------------------------------------------------|---------|---------------------------------------------------|
| R1<br>1 | <code>raw_documents</code> / <code>knowledge_objects</code> ohne Retention/Archiv → unbegrenztes Wachstum                          | mittel  | grep retention=0                                  |
| R1<br>2 | Helmut Datenmotor — Kritischer Audit Briefing→Decision nicht relational verlinkt → „warum stand das im Briefing“ nicht auditierbar | mittel  | storage.js:1630-1636 <span>Vertraulich · 2</span> |
| R1<br>3 | <code>HELMUT_*_GATE=on</code> / <code>PARDOK=on</code> schalten still nichts scharf (trügerischer Wert)                            | mittel  | understanding.js:685; pardok-dispatch.js:41       |
| R1<br>4 | 05:30-UTC-Überlappung understanding-Cron + watchdog-Pipeline ohne gemeinsamen Lock                                                 | mittel  | vercel.json + briefing-watchdog.yml               |
| R1<br>5 | <code>HELMUT_MAX_LLM_CALLS_PER_DAY</code> versehentlich leer → dauerhaft 50 statt 100, nur 1x Warnung                              | mittel  | storage.js:600-611                                |

## 14. Offene Gründerentscheidungen

Nur Fragen, die **nicht** durch Codeanalyse beantwortbar sind. Detailstruktur (Optionen/Empfehlung/Risiko/Dringlichkeit) siehe `docs/helmut_datenmotor_umsetzungsplan.md`, Abschnitt „Offene Gründerentscheidungen“.

- 1. **Prod-Env-Werte bestätigen** (nicht einsehbar): `HELMUT_MAX_LLM_CALLS_PER_DAY` (50 vs. 100?), `HELMUT_V3_MATCHING`, `HELMUT_V3_LAZY_UNDERSTANDING`, `HELMUT_LLM_BUDGET_FAIL_CLOSED`, `HELMUT_UNDERSTANDING_LOCK`, `HELMUT_LLM_RESERVE_UNDERSTANDING`, `HELMUT_AUTH_MODE`, `HELMUT_DIP_PRIMARY`, `HELMUT_MORNING_PUSH_ALL_PROFILES`, `HELMUT_MONITORING_WEBHOOK_URL`.
- 2. **KO-Backfill freigeben** (kostenneutral, 0 KI) für die 247 Alt-KOs → Ebene/Feature-Vektor.
- 3. **Blob→relational-Migration** der Betriebsdaten (Crawl-Läufe/Locks/Kosten) vor Landtag-Skalierung terminieren.
- 4. **Landtag-Cutover-Umfang** BE/BB freigeben (2 Codeänderungen + Datenaktivierung) oder verschieben.
- 5. **Scoring scharfschalten** (`HELMUT_SCORING_MODE`) — heute Default aus; nötig für ebenen-gewichtete Lage.
- 6. **Persistenz von** `decisions` / `matching_results` : als Output-Quelle nutzen, alle Profile loopen, oder als reine Telemetrie führen + Cleanup.
- 7. **Monitoring härten**: Pipeline-Fehler in `systemErrors`, `compactStore` -Whitelist um Diagnosefelder, Zweitkanal + Meta-Heartbeat.
- 8. `sources` / `rawItems` -**Blob eingefroren?** (Datenfrage, nicht codeseitig belegbar).
- 9. **Sommer-/Winterzeit-Drift** der Crons akzeptieren oder auf Ortszeit umstellen.

\*Ende Auditbericht. Umsetzungsschritte mit Priorisierung P0–P3: `docs/helmut_datenmotor_umsetzungsplan.md`.\*