

Helmut Datenmotor — Thread 2

Gründer-Freigabe & Werte-Übersicht · Entscheidungsvorlage vor dem kontrollierten Production-Teil

Ausgangs-Commit: origin/main = 427295c (PR #94) · **Branch:** claude/helmut-datenmotor-impl-2-kd1jl9 (gepusht) · **HEAD:** 9b13ad3 · **Prüfdatum:** 2026-07-16
Tests: Offline 116/116 grün · Browser-/Mobil-Smoke 32/32 grün · adversariale Diff-Review: 5 Punkte gefunden & behoben
Stand: alle verhaltensändernden Neuerungen sind **default AUS**. Kein Merge, kein Deploy, keine Migration, kein Prod-Write erfolgt. PR #88 NICHT übernommen.

Kein Betriebsreife-Nachweis, keine DSGVO-Konformitätsaussage. Es gibt **null** gemessene Production-Laufzeiten — die Messung ist Teil der Beweisläufe nach Freigabe. Die endgültigen Betriebsdokumente entstehen erst danach.

1 · Was umgesetzt wurde (alle P0 + alle P1)

ID	Umsetzung	Aktiv?
P0-2	compactStore-Allowlist erhält durationMs/understanding/googleUrlResolution/sourceMode/runId	aktiv (additiv)
P0-1	Echte Wall-Clock-Messung: Crawl, Pipeline, Lage, Understanding-Batch, Briefing-Aufbau + jeder einzelne Quellenabruf (18 techn. Felder → neue relationale Tabelle)	Prozess aktiv Pro-Quelle: Gate
P0-3	Zentraler, datenschutzsicherer Pipeline-Fehler-Sammler → systemErrors (Dedup, nur Metadaten)	aktiv (additiv)
P0-4	Atomarer, fail-closed Pipeline-Lock (Postgres-Funktion) + 05:30-Überlappungs-Koordination	freigabepflichtig
P0-5	Stufe 1: Blob-Retry+Backoff, systemError statt stiller Lauf-Verlust, non-lossy Retention · Stufe 2: Crawl-Läufe → relational vorbereitet	Stufe 1 aktiv Stufe 2 Gate
P1-9/2/5/6/8	Stale-Kommentare · Ebenen-Casing klein · ehrlicher Durchsatz (relationale Deltas) · Health-Achsen (Budget/Leerlauf/Frische/Abdeckung) · Radar-Störungswahrheit	additiv aktiv
P1-4	Begrenzter Auto-Retry fehlgeschlagener Wissensobjekte (bounded, terminal nach 2)	freigabepflichtig
P1-7	Alarm-Payload-Datenschutz-Leitplanke + Meta-Heartbeat (health-watch.yml, nur manuell)	Härtung aktiv Kanal Gate
P1-1	KO-Klassifikations-Backfill vollständig geprüft, Trockenlauf-Nachweis (247 KOs)	freigabepflichtig
P1-3	Understanding-Priorisierung scharf-schaltbar (amtlich zuerst)	freigabepflichtig

2 · Gründer-Entscheidungen F1–F8 — bitte einzeln freigeben

F1 · Deploy des Feature-Branches nach main (Vercel Production) — Empfehlung: JA
Erklärung Alle additiven Beobachtbarkeits-/Härtungs-Änderungen live schalten (P0-1/2/3, P0-5 Stufe 1, P1-2/5/6/8/9, Datenschutz-Härtung).
Vorteil Laufzeiten/Fehler werden sichtbar; ehrlicher Durchsatz; Retry gegen Blob-Timeouts.
Risiko gering — additiv, alles Verhaltensändernde default-aus, 116/116 grün.
Ohne Freigabe Motor bleibt blind (keine persistierten Laufzeiten/Fehler).
Rollback Revert des Merges / vorheriger Vercel-Deploy.
Entscheidung: ☐ JA ☐ NEIN ☐ SPÄTER Datum: _____

F2 · Migration 20260719 + HELMUT_ATOMIC_LOCK=on (+ HELMUT_UNDERSTANDING_LOCK=on) — Empfehlung: JA (nach F1)
Erklärung Atomaren, fail-closed Pipeline-Lock scharfschalten.
Vorteil schließt Doppelverarbeitung/Doppel-KI-Kosten (R2) + 05:30-Überlappung (R14).
Risiko Verhaltensänderung — fail-closed verweigert bei DB-Fehler (gewollt); vor Aktivierung Beweislauf im Überlappungsfenster.
Ohne Freigabe Doppelverarbeitung bei Blob-Instabilität möglich.
Rollback Flag `off` (Blob-Lock) + Migrations-Rollback.
Entscheidung: ☐ JA ☐ NEIN ☐ SPÄTER Datum: _____

F3 · Migration 20260718 + HELMUT_SOURCE_TELEMETRY=on — Empfehlung: JA

Erklärung Pro-Quellenabruf-Telemetrie (18 technische Felder) relational schreiben.
Vorteil echte Pro-Quelle-Laufzeit/Erfolg — der größte Beobachtbarkeits-Mangel.
Risiko gering — nur technische Metadaten, fail-safe.
Ohne Freigabe Pro-Quelle-Ebene bleibt aggregiert.
Rollback Flag `off` + Migrations-Rollback.

Entscheidung: ☐ JA ☐ NEIN ☐ SPÄTER Datum: _____

F4 · KO-Klassifikations-Backfill ausführen (247 Alt-KOs) — Empfehlung: JA (kostenneutral, 0 KI)

Erklärung `ko-classification-backfill.js --execute` auf Prod; idempotent, deterministisch.
Vorteil ~3× größerer nutzbarer KO-Bestand (Ebene + Feature-Vektor).
Risiko sehr gering — additiv, Trockenlauf belegt.
Ohne Freigabe Matching wirkt nur auf ~21 % des Bestands.
Rollback beide Felder wieder auf null (Idempotenz).

Entscheidung: ☐ JA ☐ NEIN ☐ SPÄTER Datum: _____

F5 · HELMUT_MONITORING_WEBHOOK_URL setzen + health-watch.yml -Schedule aktivieren — Empfehlung: JA

Erklärung Zweiter, unabhängiger Alarmkanal + Meta-Heartbeat.
Vorteil unabhängiger Alarm, wenn CallMeBot/Report-Cron ausfällt.
Risiko gering — Payload datenschutzgehärtet (nur technischer Status).
Ohne Freigabe einziger Alarmweg bleibt CallMeBot (fail-open/still).
Rollback URL entfernen / Schedule auskommentieren.

Entscheidung: ☐ JA ☐ NEIN ☐ SPÄTER Webhook-URL bereitstellen: _____

F6 · HELMUT_FAILED_KO_RECOVERY=on (P1-4) — optional — Empfehlung: JA, erst NACH einem Beweistag

Erklärung Begrenzter Auto-Retry fehlgeschlagener Wissensobjekte.
Vorteil verlorene Vorgänge werden wieder sichtbar (R6).
Risiko schreibt Prod-KOs — bounded, terminal nach 2 Retries.
Ohne Freigabe failed-KOs bleiben dauerhaft unsichtbar.
Rollback Flag `off`.

Entscheidung: ☐ JA ☐ NEIN ☐ SPÄTER Datum: _____

F7 · HELMUT_UNDERSTANDING_PRIORITY=on (P1-3) — optional — Empfehlung: JA für Bundestag, nach Beobachtung

Erklärung Priorisierung scharfschalten (amtlich > hohe Relevanz > Frist > Wichtigkeit > regional > Grenzfall).
Vorteil amtliche Vorgänge zuerst statt Ankunftsreihenfolge.
Risiko sichtbare Reihenfolgeänderung — vor Aktivierung an Realdaten prüfen.
Ohne Freigabe späte amtliche Vorgänge hungern bei Budgetdeckel aus.
Rollback Flag `off` (byte-identische Ankunftsreihenfolge).

Entscheidung: ☐ JA ☐ NEIN ☐ SPÄTER Datum: _____

F8 · Blob → relational Crawl-Läufe (P0-5 Stufe 2) + Retention-Fristen — später — Empfehlung: nach Bundestagspilot-Härtung, Fristen mit Rechtsprüfung

Erklärung Migration 20260720 + HELMUT_CRAWL_RUNS_RELATIONAL=on (Dual-Write); Retention-Fristen (s. §5) + HELMUT_RETENTION_EXECUTE.
Vorteil Blob-Entlastung; Speicherbegrenzung (Art. 5 DSGVO).
Risiko mittel — zentraler Speicherpfad / echte Löschung.
Ohne Freigabe Blob wächst weiter; keine Löschung.
Rollback Flags `off` + Migrations-/Löschkonzept-Rollback.

Entscheidung: ☐ JA ☐ NEIN ☐ SPÄTER Datum: _____

3 · E1 — Prod-Env-Werte bestätigen (nur „gesetz/Kategorie“ — KEINE Secrets eintragen)

Diese Werte sind aus der Arbeitsumgebung nicht lesbar. Bitte je Variable nur die Kategorie/den Boolean bestätigen.

Env-Variable	Frage	Ist-Wert (eintragen)
HELMUT_MAX_LLM_CALLS_PER_DAY	50 oder 100?	_____
HELMUT_UNDERSTANDING_LOCK	an / aus?	_____
HELMUT_LLM_BUDGET_FAIL_CLOSED	an / aus?	_____

HELMUT_LLM_RESERVE_UNDERSTANDING	Wert (z. B. 30) / leer?	
HELMUT_V3_MATCHING	an / aus?	
HELMUT_V3_LAZY_UNDERSTANDING	an / aus?	
HELMUT_AUTH_MODE	single / accounts?	
HELMUT_DIP_PRIMARY	an / aus?	
HELMUT_MORNING_PUSH_ALL_PROFILES	an / aus?	
HELMUT_MONITORING_WEBHOOK_URL	gesetzt? (nur ja/nein)	

4 · Vorbereitete Migrationen (NICHT auf Production angewendet)

Migration	Zweck	Rollback
20260718_source_crawl_telemetry.sql	Pro-Quellenabruf-Telemetrie (P0-1)	vorhanden
20260719_pipeline_lock_atomic.sql	Atomarer fail-closed Lock (P0-4)	vorhanden
20260720_crawl_runs_relational.sql	Crawl-Läufe relational, Dual-Write (P0-5 Stufe 2)	vorhanden

Alle: RLS service-role-only, idempotent, mit Rollback-Datei. Anwendung = Freigabepunkt (F2/F3/F8).

5 · Retention-Empfehlung — Datenklassen-Matrix (Fristen = Gründer + Rechtsprüfung)

Datenklasse	Tabelle	Art. 9?	Empf. Aufbewahrung
Quellen-Inhalt (minimiert)	raw_documents	nein	180 Tage
Politische Analyse	knowledge_objects	JA	365 Tage
Provenienz	ko_document_links / document_findings	nein	folgt Parent (Kaskade)
Technische Telemetrie	source_crawl_telemetry / gate_shadow_events	nein	90 Tage
Fehler / Prozess-Laufzeit	systemErrors / processRuns	nein	90 Tage (Ring)
Nutzer-Ausgabe	briefings	JA	90 Tage

Fristen bestätigt? ☐ JA ☐ ANPASSEN Rechtsprüfung erfolgt am: _____

6 · DSFA-Vorprüfung — Ergebnis

Technisch angezeigt: JA. Mehrere Art.-35-Kriterien erfüllt: systematisches Scoring von Personen · Art.-9-Daten (politische Meinung/Partei) · umfangreiche Verarbeitung · externe KI (Azure OpenAI, EU). **Die verbindliche Feststellung + Durchführung der DSFA ist eine juristische Entscheidung.**

Offen (juristisch): Rechtsgrundlage (Art. 6/9) · Aufbewahrungsfristen · AVV Azure · Betroffenenrechte-Prozess · Wirkung von Scoring/Priorisierung. Details: docs/recht/datenschutz-folgenabschaetzung-vorpruefung.md.

7 · Bereitschaftsurteil (ehrlich)

Code + Offline-Logik sind belastbar und getestet (116/116). **Betriebsreife im Sinne des überwachten Piloten ist NOCH NICHT nachgewiesen** — dafür fehlen die echten Production-Beweisläufe. **Keine DSGVO-Konformitätsaussage** ohne dokumentierte juristische Prüfung.

Nach Freigabe (im selben Thread): Deploy → Migrationen → Backfill → mind. 3 echte Crawl-Läufe + 1 Morgenzyklus → Überlappungsfenster prüfen → Fehlerfall simulieren + Wiederherstellung → Zweitkanal testen → Backfill-Idempotenz belegen → **echte** Pro-Quelle-Laufzeiten (Ø/Median/Min/Max je Prozess & Quelle) erfassen → erst dann endgültige Betriebsdokumente.

Dokumente: docs/betrieb/aufbewahrung-loeschung.md · docs/recht/datenschutz-folgenabschaetzung-vorpruefung.md · docs/betrieb/blob-relational-migration-plan.md · docs/betrieb/env-inventar.md · **Commits:** 20 auf claude/helmut-datenmotor-impl-2-kd1jl9 (HEAD 9b13ad3).